CAHIER DES CHARGES
Analyse de conversations patient-thérapeute sur la santé mentale

Encadrante : Lynda Tamine-Lechani

5 mars 2026

Ceci est une version du cahier des charges du projet qui, comme tout cahier des charges qui se respecte, est susceptible d'évoluer en fonction de la demande, des questions et remarques. Des mises à jour seront faîtes, si besoin.

Mots-clefs

Analyse de texte - Traitement de données - Statistiques

Table des matières

I Descriptif **3**

II Organisation et gouvernance du projet **4**
II.1 Organisation des groupes 4
II.2 Définition des rôles 4
II.3 Cadence des réunions et Communications 4

III Méthode **5**
III.1 Étape 1 - Exploration du jeu de données 5
III.2 Étape 2 - Analyse des sentiments des conversations 5
III.3 Étape 3 - Accès aux conversations 5
III.3.1 Groupe 1 - Résumé des conversations 6
III.3.2 Groupe 2 - Question-réponse sur la santé mentale 6

IV Livrables **7**

V Ressources **8**

I – Descriptif

La santé mentale est un enjeu majeur de la santé publique. Ce projet vise, dans un premier temps, à exploiter le jeu de données pour comprendre les types de conversations et leur structure, puis à analyser les sentiments des échanges afin de détecter les émotions et états psychologiques des patients. Ensuite, il se concentre sur l'accès et le traitement des conversations, en résumant les échanges et en identifiant les schémas linguistiques récurrents. Enfin, il prévoit le développement d'un système question-réponse, capable d'automatiser les interactions et fournir des réponses.

II – Organisation et gouvernance du projet

Compte tenue de l'envergure du projet, une structure hiérarchique est mise en place pour assurer la coordination entre l'exploration commune et les développements spécifique.

II.1 Organisation des groupes

L'effectif total est divisé en deux groupes de travail distincts qui collaboreront sur les première étapes avant de se spécialiser sur l'étape 3.
Le groupe 1 sera spécialisé sur "Partie 1 : Résumé des conversations" (voir sous-section III.3.1) et le groupe 2 sur "Partie 2 : Question-réponse sur la santé mentale" (voir sous-section III.3.2)

II.2 Définition des rôles

- **Chef de Projet (Global) :** Il est garant de la cohérence globale. Il supervise les deux groupes, s'assure du respect du diagramme de Gantt, consolide les livrables et assure la communication officielle avec l'encadrante.
- **Chef de groupe (1 par groupe) :** Il gère le planning interne de son groupe, répartit les tâches techniques de la semaine et prépare les points de synchronisation.
- **Membres du groupes :** Chaque membre se verra attribuer des rôles technique.

Chef de projet : LARROUX Logan

GROUPE 1 **(Résumé conversations)** **Chef de groupe : (à déterminer)**	**GROUPE 2** **(Q/R sur santé mentale)** **Chef de groupe : Idir Yahiaoui**
Ulysse Chasseigne Cruz Fernandes Diogo Emin Belkheir LARROUX Logan Victor Blanquart–Blanchet	Idir Yahiaoui Bantsoukissa Laure Esso-Y-N Trésor PANA Yvan Sellier

II.3 Cadence des réunions et Communications

Pour chaque sous-groupes, une réunion prévu toute les semaines sera organisé pour mettre en revue l'avancement technique, l'identification des points de blocages (bugs, limites des modèles) et définition des objectifs de la semaine suivante. Le chef de groupe compile ces informations.
Une rencontre entre les chefs de groupe et le chef de projet se fera quand à lui au moins 2 fois par mois. L'objectif est de réunir tout les feed-back reçus par les deux chefs de groupe et préparer un reporting pour la référente.

III – Méthode

III.1 Étape 1 - Exploration du jeu de données

Objectif : Comprendre la structure du corpus et identifier les thématiques majeurs. Les deux groupes réalisent cette étape en parallèle puis compare leurs résultats.

Le fichier *train.csv* (voir chapitre V) comporte une grande base de données sur deux colonnes : la première est le patient conversant avec le psychologue et la seconde est la réponse du psychologue au patient. Cette première partie a plusieurs buts :

- **Nettoyage des données (Pré-traitement) :** Suppression de la ponctuations, tokenisation, lemmatisation et retrait des mots vides *(stop-words)*.
- **Analyse Statistique :** Création d'un tableau récapitulatif via des scripts Python (Pandas) pour extraire :
  - le nombre de patients uniques
  - le nombre de thérapeutes
  - la distribution des conversations par thérapeute
  - nombre d'échanges moyen par conversation
- **Analyse Lexicale :** génération d'un dictionnaire lexicale (n-grams) avec le calcul des fréquences d'apparition des mots par patients, par thérapeutes et par conversassions.
- **Modélisation et Extraction de Sujets *(Topic Modeling)*** : Pour cette section, le but est d'utiliser les différentes méthodes et de comparer les résultats entre elles, les méthodes sont :
  - Méthode 1 : Filtrage via un lexique métier défini manuellement (ex : stress, anxiété, sommeil, dépression).
  - Méthode 2 : Vectorisation TF-IDF (Term Frequency-Inverse Document Frequency) suivie d'un clustering (algorithme K-Means) pour regrouper les mots mathématiquement proches.
  - Méthode 3 : Utilisation Word Embedding (Word2Vec ou GloVc) pour capturer le contexte sémantique, couplé à un clustering.
  - Méthode 4 : Entraînement d'un modèle probabiliste LDA (Latent Dirichlet Allocation) pour faire émerger les sujets latents purs.

III.2 Étape 2 - Analyse des sentiments des conversations

Objectif : quantifier la "polarité" et les émotions des échanges. Les deux groupes comparent leurs approches.

Cette section est en cours de développement

III.3 Étape 3 - Accès aux conversations

À l'issue des étapes 1 et 2, les groupes se séparent pour développer deux outils distincts d'accès à l'information.

III.3.1 Groupe 1 - Résumé des conversations

Cette section est en cours de développement

III.3.2 Groupe 2 - Question-réponse sur la santé mentale

Cette section est en cours de développement

IV – Livrables

À l'issue de la période de développement, les éléments suivants seront remis au **responsable de la matière** :

- **Dépôt du cahier des charge de développement** listant le travail à effectuer ou expliquant les objectifs et la méthode de travail.
  Dépôt prévu le 15 mars 2026
- **Bilan de mi-parcours et mise à jour du prévisionnel** est une mise à jour du rapport préliminaire. On listera les objectifs atteints, les succès et difficultés, le travail restant ou perspectives à tester.
  Dépôt prévu le 20 avril 2026
- **Dépôt du livrable final** qui comporte deux fichiers :
  — **Le rapport de compte rendu du projet**
  — **La documentation technique de développement**
  La longueur demandée est d'une dizaine de pages, sans compter la page de garde, dans une police de caractères de taille raisonnable (pas trop grosse, pas trop petite, pas plis de 12 pts), avec des marges de taille raisonnable.
  Dépôt prévu le 1 juin 2026

V – Ressources

- Ensemble de données publié par KAGGLE sur des conversation patient-Thérapeute `https://www.kaggle.com/datasets/thedevastator/nlp-mental-health-conversations`