# CAHIER DES CHARGES
# Analyse de conversations patient-thérapeute sur la santé mentale

**Encadrante : Lynda Tamine-Lechani**

7 avril 2026

Ceci est une version du cahier des charges du projet qui, comme tout cahier des charges qui se respecte, est susceptible d'évoluer en fonction de la demande, des questions et remarques. Des mises à jour seront faites, si besoin.

**Mots-clefs**

Analyse de texte - Traitement de données - Statistiques

## Participants :

Ulysse Chasseigne
Idir Yahiaoui
Bantsoukissa Laure
Cruz Fernandes Diogo
Emin Belkheir
Esso-Y-N Trésor PANA
LARROUX Logan
Yvan Sellier
Victor Blanquart–Blanchet
Lucas Da Silva

# Table des matières

**I Descriptif** **3**

**II Organisation et gouvernance du projet** **4**
II.1 Organisation des groupes . . . . . 4
II.2 Définition des rôles . . . . . 4
II.3 Structure du projet et des documents . . . . . 5
II.4 Cadence des réunions et Communications . . . . . 6

**III Méthode** **7**
III.1 Étape 1 - Exploration du jeu de données . . . . . 7
III.2 Étape 2 - Analyse des sentiments des conversations . . . . . 7
III.3 Étape 3 - Accès aux conversations . . . . . 7
III.3.1 Groupe 1 - Résumé des conversations . . . . . 8
III.3.2 Groupe 2 - Question-réponse sur la santé mentale . . . . . 8

**IV Livrables** **9**

**V Ressources** **10**

# I – Descriptif

La santé mentale est un enjeu majeur de la santé publique. Ce projet vise, dans un premier temps, à exploiter le jeu de données pour comprendre les types de conversations et leur structure, puis à analyser les sentiments des échanges afin de détecter les émotions et états psychologiques des patients. Ensuite, il se concentre sur l'accès et le traitement des conversations, en résumant les échanges et en identifiant les schémas linguistiques récurrents. Enfin, il prévoit le développement d'un système question-réponse, capable d'automatiser les interactions et fournir des réponses.

# II – Organisation et gouvernance du projet

Compte tenu de l'envergure du projet, une structure hiérarchique est mise en place pour assurer la coordination entre l'exploration commune et les développements spécifiques.

## II.1 Organisation des groupes

L'organisation changera deux fois durant ce projet.
Dans un premier temps les étapes 1 et 2 se feront de façon individuelle. Chacun devra traiter de son côté ses données afin d'en extraire des informations qui peuvent être par la suite comparées. Puis dans un second temps, pour la troisième partie, l'effectif total est divisé en deux groupes distincts. Le groupe 1 sera spécialisé sur "Partie 1 : Résumé des conversations" (voir sous-section III.3.1) et le groupe 2 sur "Partie 2 : Question-réponse sur la santé mentale" (voir sous-section III.3.2).

## II.2 Définition des rôles

- **Chef de Projet (Global) :** Il est garant de la cohérence globale. Il supervise les deux groupes, s'assure du respect du diagramme de Gantt, consolide les livrables et assure la communication officielle avec l'encadrante.
- **Chef de groupe (1 par groupe) :** Il gère le planning interne de son groupe, répartit les tâches techniques de la semaine et prépare les points de synchronisation.
- **Membres du groupe :** Chaque membre se verra attribuer des rôles techniques.

**Chef de projet : LARROUX Logan**

| **GROUPE 1**<br>**(Résumé conversations)**<br>**Chef de groupe : Cruz Fernandes Diogo** | **GROUPE 2**<br>**(Q/R sur santé mentale)**<br>**Chef de groupe : Idir Yahiaoui** |
|---|---|
| Ulysse Chasseigne<br>Cruz Fernandes Diogo<br>Emin Belkheir<br>LARROUX Logan<br>Victor Blanquart–Blanchet | Idir Yahiaoui<br>Bantsoukissa Laure<br>Esso-Y-N Trésor PANA<br>Yvan Sellier<br>Lucas Da Silva |

## II.3 Structure du projet et des documents

Le projet sera séparé en **deux structures distinctes** afin d'améliorer sa lisibilité.
La première sera hébergée sur **GitHub**. Elle **centralise le travail de l'équipe**, en plus d'un compte rendu détaillé et ciblé sur les méthodes et fonctions utilisées pour chaque étapes du projet.
La seconde sera sur **Google Drive**, plus orientée vers le **suivi de projet**, elle regroupera les avancées de tout le monde (triées de façon hebdomadaire), les résultats obtenues par l'équipe sur plusieurs données demandés dans l'étape ciblée et enfin, un compte rendu sous format **bi-mensuel** résumant les avancée globale, problématiques rencontrés et questions à poser lors des réunion avec la référent.
Ces deux structures devront être respectées pour permettre une organisation claire, stable et efficace du projet.

### Structure du projet sur GitHub

```
/
├── data
│   └── trains.csv
├── notebooks                                # Travail technique de l'équipe
│   ├── CRUZDiogo
│   ├── EMIN
│   ├── LAURE
│   ├── LOGAN
│   ├── LUCAS
│   ├── TRESOR
│   ├── YVAN
│   └── IDIR
└── comptes_rendus           # Explication détaillé des résultats de l'équipe
    ├── compte_rendu_etape1.md
    ├── compte_rendu_etape2.md
    └── compte_rendu_etape3.md
```

### Structure du projet sur Google Drive

```
/
├── DOCUMENTATION
│   ├── BE__Cahier_des_charges.pdf
│   └── BE__Gantt.gan
├── CHECK_UPS                                # Avancée global de l'équipe
│   └── Check-ups_hebdomadaire.xlsx
├── RESULTATS_DONNEES                # Récolte des données global de l'équipe
│   ├── Resultats_etape_1.xlsx
│   ├── Resultats_etape_2.xlsx
│   ├── Resultats_etape_3_groupe1.xlsx
│   └── Resultats_etape_3_groupe2.xlsx
└── RENDUS_TECH                       # Techniques, problèmes, questions etc.
    ├── rendu_tech_{Date_RDV}.pdf
    └── ...
```

## II.4 Cadence des réunions et Communications

Pour chaque sous-groupe, une réunion prévue **toutes les semaines** sera organisée pour mettre en revue l'avancement technique, l'identification des points de blocages (bugs, limites des modèles) et définition des objectifs de la semaine suivante. Le chef de groupe compile ces informations et va, par la suite, faire son propre compte-rendu de l'avancée globale.
Ce compte rendu sera ensuite mis à disposition lors des réunions avec la référent, ses réunions se feront au moins **2 fois par mois**. L'objectif est de réunir tout les feed-backs reçus par les deux chefs de groupe et préparer un reporting pour la référente.

| **Avril** | **Mai** |
|---|---|
| Mardi 14 (17h-18h) | Mardi 12 (17h-18h) |
| Mardi 28 (17h-18h) | Mardi 26 (17h-18h) |

Ces dates sont susceptibles de changer en fonctions des disponibilités de chacun.

# III – Méthode

## III.1 Étape 1 - Exploration du jeu de données

*Objectif : Comprendre la structure du corpus et identifier les thématiques majeures. Les deux groupes réalisent cette étape en parallèle puis compare leurs résultats.*

Le fichier *train.csv* (voir chapitre V) comporte une grande base de données sur deux colonnes : la première est le patient conversant avec le psychologue et la seconde est la réponse du psychologue au patient. Cette première partie a plusieurs buts :

- **Nettoyage des données (Pré-traitement) :** Suppression de la ponctuation, tokenisation, lemmatisation et retrait des mots vides *(stop-words)*.
- **Analyse Statistique :** Création d'un tableau récapitulatif via des scripts Python (Pandas) pour extraire :
  - le nombre de patients uniques
  - le nombre de thérapeutes
  - la distribution des conversations par thérapeute
  - nombre d'échanges moyen par conversation
- **Analyse Lexicale :** génération d'un dictionnaire lexical (n-grams) avec le calcul des fréquences d'apparition des mots par patients, par thérapeutes et par conversations.
- **Modélisation et Extraction de Sujets *(Topic Modeling)*** : Pour cette section, le but est d'utiliser les différentes méthodes et de comparer les résultats entre elles, les méthodes sont :
  - Méthode 1 : Filtrage via un lexique métier défini manuellement (ex : stress, anxiété, sommeil, dépression).
  - Méthode 2 : Vectorisation TF-IDF (Term Frequency-Inverse Document Frequency) suivie d'un clustering (algorithme K-Means) pour regrouper les mots mathématiquement proches.
  - Méthode 3 : Utilisation Word Embedding (Word2Vec ou GloVc) pour capturer le contexte sémantique, couplé à un clustering.
  - Méthode 4 : Entraînement d'un modèle probabiliste LDA (Latent Dirichlet Allocation) pour faire émerger les sujets latents purs.

## III.2 Étape 2 - Analyse des sentiments des conversations

*Objectif : quantifier la "polarité" et les émotions des échanges. Les deux groupes comparent leurs approches.*

Cette section, n'étant pas encore détaillée par la référente, est en cours de développement.

## III.3 Étape 3 - Accès aux conversations

À l'issue des étapes 1 et 2, les groupes se séparent pour développer deux outils distincts d'accès à l'information.

### III.3.1 Groupe 1 - Résumé des conversations

Cette section, n'étant pas encore détaillée par la référente, est en cours de développement.

### III.3.2 Groupe 2 - Question-réponse sur la santé mentale

Cette section, n'étant pas encore détaillée par la référente, est en cours de développement.

# IV – Livrables

À l'issue de la période de développement, les éléments suivants seront remis au **responsable de la matière** (Monsieur Vincent DUGAT) et à la **référente du projet** (Madame Lynda TAMINE-LECHANI) :

- **Dépôt du cahier des charges de développement** listant le travail à effectuer ou expliquant les objectifs et la méthode de travail.
  *Dépôt prévu le 15 mars 2026*
- **Bilan de mi-parcours et mise à jour du prévisionnel** est une mise à jour du rapport préliminaire. On listera les objectifs atteints, les succès et difficultés, le travail restant ou perspectives à tester.
  *Dépôt prévu le 20 avril 2026*
- **Dépôt du livrable final** qui comporte deux fichiers :
  — **Le rapport de compte rendu du projet**
  — **La documentation technique de développement**
  La longueur demandée est d'une dizaine de pages, sans compter la page de garde, dans une police de caractères de taille raisonnable (pas trop grosse, pas trop petite, pas plus de 12 pts), avec des marges de taille raisonnable.
  *Dépôt prévu le 1 juin 2026*
- **Livrable technique** décrivant brièvement les principales techniques, ressources utilisées et les possibles problèmes rencontrés lors de l'avancé.
  *Dépôt prévu bi-mensuel*
- **Compte rendu des étapes** décrivant les résultats obtenu par chacun des membres de l'équipe, les similarité et surtout les différences observées, justifiées de façon claire et concise.
  *Dépôt prévu à chaque fin d'étape*

# V – Ressources

- Ensemble de données publié par KAGGLE sur des conversations patient-Thérapeute
- Page GitHub de l'équipe